

# Arbeitsblatt: Logistische Regression

## Binäre Klassifikation mit Wahrscheinlichkeiten

### Informatik

#### 1. Lernziel

Ich kann

- den Zweck der logistischen Regression erklären (Ja/Nein-Vorhersage)
- die Sigmoid-Funktion anwenden, um eine Wahrscheinlichkeit zu berechnen
- Kategorien vorhersagen und einfache Metriken (Accuracy) interpretieren

#### 2. Was macht die logistische Regression?

Die Logistische Regression wird für **binäre Klassifikationsaufgaben** genutzt, also wenn die Antwort nur zwei Werte annehmen kann, z.B.: Ja/Nein, 0/1, Wahr/Falsch.

Analog zur linearen Regression wird auch hier eine Gerade berechnet, aber das Ergebnis wird **in eine Wahrscheinlichkeit umgewandelt** (z.B. die Wahrscheinlichkeit, ob eine Schüler:in den Test besteht oder nicht). Somit sagt die logistische Regression **keine direkten Kategorien** vorher, sondern **Wahrscheinlichkeiten** für die Kategorien.

Bedeutung der Wahrscheinlichkeit  $p$ :

- Beispiel:  $p = 0.8$  bedeutet, dass das Modell zu 80% sicher ist, dass die Kategorie 1 (z.B. „bestanden“) zutrifft.
- Beispiel:  $p = 0.3$  bedeutet, dass das Modell zu 70% sicher ist, dass die Kategorie 0 (z.B. „nicht bestanden“) zutrifft.

Nach Berechnung der Wahrscheinlichkeit wird eine **Schwelle** (z.B. 0.5) genutzt, um die Wahrscheinlichkeit in eine konkrete Kategorie umzuwandeln.

##### 2.1 Ablauf in drei Schritten

- 1) Rechne eine **Gerade**:  $z = ax + b$ .
- 2) Setze  $z$  in die **Sigmoid-Funktion**  $\sigma(z)$  ein und erhalte eine Wahrscheinlichkeit  $p \in (0, 1)$ .
- 3) Setze eine **Schwelle** (oft 0.5), um aus  $p$  eine Kategorie zu machen.

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Anmerkungen:

- **Entscheidungsgrenze:**  $p = 0.5$  entspricht  $z = 0$ .
- **Typische Regel:**  $\hat{y} = 1$  falls  $p \geq 0.5$ , sonst  $\hat{y} = 0$ .
- **Schwelle anpassbar:** Höhere Schwelle = strenger, niedrigere Schwelle = grosszügiger.

### 3. Mini-Übung: Sigmoid skizzieren

- Zeichne die Kurve von  $\sigma(z)$  für  $z \in [-6, 6]$  in das Gitter unten.
- Berechne selbst die gerundeten Werte  $\sigma(z)$  für die ganzzahligen Punkte  $z = -6, \dots, 6$  und trage sie in die Tabelle ein.

$z$	$\sigma(z)$
-6	
-5	
-4	
-3	
-2	
-1	
0	
1	
2	
3	
4	
5	
6	

- Zeige, dass die Kurve bei 0.5 „umkippt“ und sich bei 0 bzw. 1 asymptotisch annähert.




Abbildung 1: Koordinatengitter (nutzen für Sigmoid)

## Beispiel 1: Besteht man den Test?

Gegebenes Modell (aus Training gelernt):

$$p = \sigma(1.2x - 2.0)$$

*Interpretation:*  $x$  = Lernzeit in Stunden,  $p$  = Wahrscheinlichkeit, den Test zu bestehen (Kategorie 1).

### Datenpunkte

Lernzeit $x$ (h)	Tatsächliches Label $y$ (0 = nicht bestanden, 1 = bestanden)
0.5	0
1.0	0
1.5	0
2.0	0
2.5	1
3.0	1

### Aufgabe 1a: Wahrscheinlichkeiten berechnen

Fülle die Tabelle aus (Zwischenschritte runden auf 3 Nachkommastellen):

$x$	$z = 1.2x - 2.0$	$p = \sigma(z)$	$\hat{y}$ (Schwelle 0.5)
0.5			
1.0			
1.5			
2.0			
2.5			
3.0			

### Aufgabe 1b: Accuracy bestimmen

- Trage  $\hat{y}$  aus der Tabelle ein und vergleiche mit  $y$ .
- Zähle die **korrekt** klassifizierten Beispiele.
- **Accuracy** = (korrekte Vorhersagen) / (Anzahl Beispiele).

Accuracy =

## Beispiel 2: Zwei Modelle vergleichen

Gleiche Datenpunkte wie oben.

### Modelle

- **Modell A:**  $p_A = \sigma(1.0x - 1.8)$
- **Modell B:**  $p_B = \sigma(1.4x - 2.9)$

### Aufgabe 2a: Wahrscheinlichkeiten & Kategorien

Berechne für beide Modelle  $p$  und  $\hat{y}$  (Schwelle 0.5) und fülle die Tabellen.

#### Modell A

$x$	$y$	$z_A = 1.0x - 1.8$	$p_A$	$\hat{y}_A$
0.5	0			
1.0	0			
1.5	0			
2.0	0			
2.5	1			
3.0	1			

#### Modell B

$x$	$y$	$z_B = 1.4x - 2.9$	$p_B$	$\hat{y}_B$
0.5	0			
1.0	0			
1.5	0			
2.0	0			
2.5	1			
3.0	1			

### Aufgabe 2b: Accuracy vergleichen

- Berechne die Accuracy von Modell A und B.
- Welches Modell ist besser? Gibt es Punkte, die ein Modell richtig und das andere falsch hat?

**Accuracy A =**

**Accuracy B =**

### Aufgabe 2c: Kurze Interpretation (2–4 Sätze)

1. Welches Modell würdest du wählen und warum?
2. Wie könnte man die Schwelle 0.5 verändern, um mehr/ weniger falsch kategorisierte Zuordnungen zu bekommen?

## Reflexion

1. In welchen Situationen ist die logistische Regression besser geeignet als die lineare Regression?
2. Warum sind Wahrscheinlichkeiten hilfreicher als nur harte 0/1-Entscheidungen?